

面向不同车型的 2.5D 野外地形风险感知路径规划 基于机器学习与搜索算法的双向嵌套设计

东北大学自动化强基班《人工智能》与《机器学习与模式识别》综合课程作业

团队成员：崔瑞航、李佳阳、刘动 指导教师：陈东岳

摘要

在野外复杂的 2.5D 地形中，传统仅依赖距离的路径规划方法难以适应不同车辆的物理通行能力差异。本设计提出了一种融合机器学习与智能优化搜索的路径规划架构：外层引入带有物理先验的风险约束 A* 算法，内层采用粒子群优化对 CNN+MLP 多任务风险预测模型进行拓扑与参数寻优。结合 Gazebo 物理仿真生成的高保真数据集以及 ML+Geometric Guard 保底机制，方案成功实现了同一复杂地形下针对不同车辆参数的自适应、低风险差异化规划。实验表明，该架构大幅降低了越野翻车和托底风险，显著提升了复杂非结构化环境下的规划成功率与系统鲁棒性。

1 问题背景与形式化定义

1.1 应用背景与工程价值

在野外救援、农业勘探与星际巡查等场景中，移动机器人常面临崎岖非结构化的 2.5D 地形。传统路径规划将车辆抽象为质点，仅优化几何距离。Gu 与 Cao[1] 将高程信息纳入 A 边代价，形成 2.5D A 基线，但该方法未考虑车型差异。在平坦室内环境中质点假设合理，但在野外地形下，轴距、轮径、底盘高度不同的车辆面临的侧翻、托底、打滑等物理风险截然不同。

若仅以三维欧氏距离为代价，极易将车辆引向危险短路。为此，本课题提出车型参数化、具备物理风险感知的约束 A 路径规划方案，引入机器学习与智能优化搜索的双向嵌套架构，实现对非线性动态风险的精准拟合与规划应用。

1.2 问题形式化定义

将野外环境表示为带有物理属性的全局 2.5D 栅格地图 $M = \{H(i, j), \mu(i, j)\}$ ，其中 H 为高程， μ 为地面摩擦系数（全局属性，每个样本为均一标量）。不同于传统 2D 规划，本课题在状态与动作空间中引入了车辆运动学与几何约束：

- **状态空间 S :** 状态定义为 $s = (i, j, k)$ ，其中 (i, j) 为车辆中心所在的栅格坐标， $k \in \{0, 1, \dots, 15\}$ 为离散化的车辆航向角（共 16 个方向，航向角 $\psi_k = 2\pi k/16$ ）。
- **动作空间 A :** 定义为一组局部运动基元 $a = [\Delta d, \Delta\psi]$ ，其中 Δd 为沿当前航向的弧长位移量（0 或 0.45 m）， $\Delta\psi$ 为航向角变化量（0 或 $\pm 22.5^\circ$ ），两者组合构成直行与不同曲率的转向动作。此处的 Δd 是位移距离，与状态变量 s 无关。
- **状态转移与边 e :** 定义边 $e = (s, a, s')$ 表示车辆从状态 s 执行动作 a 到达 s' 的过渡过程。每条边不仅具有几何长度代价 $d_e = \Delta d$ ，更包含通过机器学习模型预测的物理交互风险 $\hat{r}_e$ 。

规划目标与约束：本课题不采用距离与风险简单线性加权的软惩罚方式，因为这种方式容易让短距离的优势掩盖高风险，而是将其建模为带硬约束的组合优化问题。给定起点 s_{start} 与目标区域 G ，寻找一条路径 $\pi = \{e_1, e_2, \dots, e_T\}$ ，使得：

$$\min_{\pi} L(\pi) = \sum_{e \in \pi} d_e \quad (1)$$

$$\begin{aligned} \hat{r}_e &\leq T_{\text{edge}}, \quad \forall e \in \pi && \text{(单步风险约束)} \\ \text{s.t. } R_{\text{max}}(\pi) &= \max_{e \in \pi} \hat{r}_e \leq T_{\text{max}} && \text{(路径最大风险约束)} \\ R_{\text{avg}}(\pi) &= \frac{\sum_{e \in \pi} d_e \hat{r}_e}{L(\pi)} \leq T_{\text{avg}} && \text{(路径平均风险约束)} \end{aligned}$$

其中 $T_{\text{edge}}, T_{\text{max}}, T_{\text{avg}}$ 为安全阈值。在此架构中，外部搜索算法需要内部机器学习模型提供精准的 $\hat{r}_e$ ，而内部模型的超参数与上述阈值又需要依赖智能搜索算法自动寻优，从而构成双向嵌套协同的需求。

2 外层设计：风险约束 A* 与机器学习启发

外层架构中，A* 搜索算法通过调用已训练好的内层机器学习模型，获取局部状态转移的物理风险估计。该风险值既作为启发信息引导搜索方向，也用于剪除高风险分支，从而大幅压缩无效的搜索空间。

2.1 风险预测模型输入与架构

传统评估方法仅考察单一栅格的状态，而物理风险实际上发生在车身扫掠整个动作区域的动态过程中。因此，将机器学习模型的输入设计为四元组 $X = (X_{\text{map}}^{s,a}, \theta_v, a, \mu)$ ：

1. **局部地形特征** $X_{\text{map}}^{s,a} \in \mathbb{R}^{31 \times 31 \times 6}$ ：以车辆当前位置为中心、沿车身航向旋转至车辆坐标系的局部地图切片。上标 (s, a) 表示状态 s 决定切片中心与朝向，动作 a 决定扫掠掩码形状。6 个通道依次为：□ 相对高程 Z ，□ 纵向坡度 G_u （影响俯仰），□ 横向坡度 G_v （影响侧翻），□ 局部粗糙度 R （高度标准差，衡量颠簸），□ 车身掩码 M_{body} ，□ 动作扫掠掩码 M_{swept} （15 个时刻车身扫过区域的并集）。
2. **车辆参数向量** $\theta_v \in \mathbb{R}^{12}$ ：包含车长 L 、车宽 W 、轴距 l 、轮距 b 、轮径 r_w 、底盘离地间隙 c_g 、质量 m 、质心高度 z_c ，以及各安全角限值 $\phi_{\text{max}}, \theta_{\text{max}}, \alpha_{\text{max}}$ 和最大驱动力 F_{max} 。
3. **动作参数 a 与 摩擦系数 μ** ： $a = [\Delta d, \Delta \psi]$ ； μ 为地面摩擦系数（标量，干地约 0.7–0.9，草地约 0.4–0.6，湿泥约 0.2–0.4）。

模型采用 **CNN + MLP 双分支融合架构**：CNN 提取 X_{map} 的空间几何特征，MLP 提取参数特征，融合后输出多任务物理风险 $\hat{y} = [\hat{y}_{\text{fail}}, \hat{q}_{\text{roll}}, \hat{q}_{\text{pitch}}, \hat{q}_{\text{slip}}, \hat{q}_{\text{lift}}, \hat{p}_{\text{bottom}}, \hat{p}_{\text{stuck}}]$ ，涵盖侧翻、俯仰、打滑、托底等多维危险概率。多维风险通过加权融合 $\hat{r}_e = \sum_i w_i \hat{y}_i$ 归并为单一标量边风险 r_{ml} 。

2.2 基于 ML+Guard 的鲁棒融合机制设计

在实际工程实现与 Gazebo 物理仿真数据收集过程中发现：为保证仿真引擎物理接触约束的稳定性，数据收集阶段的稳定性门控客观上过滤掉了部分极端非平坦地形，导致机器学习模型在面临断崖等极高频凸起时可能因分布外数据而低估风险。

为保证系统在任意未知地图上的绝对安全性与可解释性，本方案在外层 A* 规划的代价评估环节提出并实现了 **ML + Geometric Guard** 融合机制，即物理先验保底机制：

$$r_{\text{plan}} = (1 - \lambda_g) r_{\text{ml}} + \lambda_g \cdot \max(r_{\text{ml}}, r_{\text{manual}}) \quad (2)$$

其中 r_{manual} 为基于局部扫描区域坡度与粗糙度的人工保守风险值， λ_g 为保底权重，本方案取 $\lambda_g = 0.5$ 。该设计既保留了 ML 模型对不同车型在复杂地形上的精细分辨力，又在 ML 可能失效的极端几何突变处提供了严格的安全性下界，使 A* 算法的硬约束剪枝逻辑更加鲁棒。

3 内层设计：PSO 智能优化模型

上述机器学习模型的网络结构、损失函数分配比例以及规划层的安全阈值均具有高度的非线性与耦合性，难以通过经验法则或简单网格搜索获得全局最优解。因此，内层采用粒子群优化算法对模型超参与规划阈值进行联合寻优。

3.1 粒子编码与搜索空间设计

每个粒子 $\mathbf{z}$ 代表一组完整的模型-规划配置，其编码维度共计 20 维，涵盖三大类：

1. **网络结构与训练参数**：CNN 各层通道数组合、隐藏层神经元个数、Dropout 比例、学习率、权重衰减系数。
2. **多任务损失权重**：对分类失败、托底、卡住、回归误差的损失函数权重 $\lambda_f, \lambda_b, \lambda_s, \lambda_r$ 进行自动分配，解决多任务学习中梯度不平衡问题。
3. **风险融合权重与规划阈值**：多维风险融合成标量的 7 维权重向量 w_i ，以及外层 A* 的硬约束阈值 $T_{\text{edge}}, T_{\text{max}}, T_{\text{avg}}$ 。

3.2 复合适应度函数设计

常规的自动机器学习方法仅以验证集损失函数作为优化目标，但本课题的最终目的是服务于路径规划，模型预测精度的提升未必等同于规划成功率的提升。因此，在内层 PSO 的评价阶段引入了代理规划评估，即在小型验证地图上实际运行 A* 规划来反馈模型质量，并将适应度函数设计为如下复合指标：

$$\text{Fitness} = \text{AUC}_{\text{fail}} + \alpha_1 \cdot \text{Recall}_{\text{fail}} - \alpha_2 \cdot \text{MAE}_{\text{risk}} - \alpha_3 \cdot t_{\text{infer}} + \beta_1 \cdot \text{PlanSR} + \beta_2 \cdot \text{OracleSR} \quad (3)$$

式中，前三项评估模型在验证集上的离线辨识精度与查全率，优先惩罚风险漏报情况； t_{infer} 惩罚过度庞大的网络结构以保证 A* 的节点扩展效率。PlanSR 代表将该粒子生成的模型投入小型验证地图进行实际 A* 规划的成功率，OracleSR 代表模型决策与真实物理标签的一致性。通过这一复合适应度函数，PSO 并非盲目地调整超参数，而是真正实现了由搜索结果反馈至模型结构的闭环优化。

4 双向嵌套协同架构：耦合机制与理论分析

在复杂的工程场景中，单一的搜索算法或机器学习模型均存在各自的性能瓶颈：搜索算法缺乏物理先验，而机器学习模型在缺少针对性结构设计时难以直接对接离散的组合优化任务。本方案的核心创新在于构建了一个数据流与控制流高度解耦、优化目标又深度耦合的双向嵌套协同架构。

4.1 整体架构与交互逻辑

图 1 展示了全流程协同机制，系统划分为三大逻辑域：物理数据引擎、内层智能搜索和外层风险约束搜索。




图 1: 机器学习与搜索双向嵌套协同架构

根据图 1：Gazebo 引擎生成高保真数据集，导入内层 CNN+MLP 网络进行特征提炼。内层 PSO 通过改变粒子位置重塑 ML 模型的网络结构和训练法则，代理 A* 接收模型输出并在小规模沙盒上规划，将不可导的规划结果转化为 Fitness 标量反馈给 PSO。外层 A* 将节点探索请求 (s, a) 下发给 ML 模型，ML 模型凭借泛化能力为每条扩展边赋予风险成本，将搜索转变为安全导向探索。

4.2 协同优化的理论优势

1. **机器学习赋能搜索。**传统 2.5D A* 仅用几何高差作为代价，属于静态惩罚，但侧翻、打滑等风险高度非线性，取决于轴距 l 、轮距 b 、底盘高度 c_g 等车辆参数与姿态的组合。外层引入经 PSO 优化的 ML 模型后，A* 搜索获得了物理引擎级别的先验知识：超过阈值 T_{edge}^* 的候选边被提前剪枝，避免搜索到死胡同才回溯。针对 ML 分布外失效风险，Geometric Guard 保底机制保证了极端地形下搜索代价的下界安全性。


2. **搜索反哺机器学习。**内层核心矛盾在于：验证集分类损失最低不等于路径规划成功率最高。A* 搜索与硬约束截断完全离散不可微，无法用梯度反馈网络结构。PSO 通过零阶黑盒优化弥补了这一短板：在验证集误差基准上，直接将代理规划成功率纳入适应度函数，促使 ML 模型不再片面追求回归误差，转而学习能切实提高车辆存活率的决策边界。

5 仿真实验设计与结果分析


实验环境：Ubuntu 24.04，ROS 2 Jazzy + Gazebo Sim 8.11（Bullet-Featherstone 物理引擎），PyTorch 2.11（CUDA 13），Intel Core i7-13700，NVIDIA RTX 4060。为验证双向嵌套协同架构的有效性，本方案完成了从底层数据生成、模型内层调优到外层路径规划的全链路闭环验证。

5.1 多模态仿真数据集与物理风险标定

本课题摒弃了缺乏物理意义的人工代价，采用 Gazebo/ros_gz 高保真物理引擎构建了包含 20,000 个局部动作过渡的交互数据集。引擎中完整配置了车辆的碰撞体、悬挂接触传感器与里程计。在程序随机生成的参数化 2.5D 地形上执行离散动作，系统自动提取侧翻、俯仰、托底、车轮悬空及打滑等多维物理风险。仿真标定真实反映了地形—车辆—动作三者的非线性交互耦合。



大型山地车右小转，判定为安全



标准越野车直行上坡，判定为临界危险

图 2: 基于 Gazebo 物理引擎的局部动作仿真与多维风险标签自动提取

图 2 展示了两个典型的物理仿真切片。左图：大型山地车（85×55 cm, 20 kg）在凸起地形执行右小转，大轮径与高底盘使其稳定通过，判定为安全。右图：标准越野车（65×45 cm, 14 kg）在斜坡凸起叠加地形直行，前轮压过凸起时短暂悬空并伴随打滑，判定为临界。这类细粒度多维物理交互是内层 ML 模型的训练基础，提供了替代人工几何代价的真实物理先验。

5.2 定量分析：双向嵌套与 ML+Guard 的消融验证

为证明内层 ML 模型及其融合机制在外层规划中的核心价值，我们在 27 张未知测试地图上针对 3 种车型共 81 个规划任务进行了消融对比实验。约束条件统一为：单步动作风险阈值 $T_{\text{edge}} = 0.70$ ，路径最大风险阈值 $T_{\text{max}} = 0.90$ ，平均风险阈值 $T_{\text{avg}} = 0.49$ 。

实验设置了五组对比方法。**Baseline 1** 为原始 2.5D A，源自 Gu 与 Cao 提出的经典方法 [1]，仅以三维欧氏距离作为边代价，完全忽略车辆物理参数与通行风险，代表传统方案的上界。**Baseline 2** 在距离代价上附加基于局部扫掠区域坡度与粗糙度的手工线性惩罚项，用于验证纯几何规则的局限性。**Baseline 3** 将 PSO 优化后的 ML 模型预测风险以线性加权形式融入代价函数，证明仅靠软惩罚难以彻底规避高风险区域。**Guard Only** 采用与 **Baseline 2** 相同的手工几何风险计算，但以 **Proposed** 相同的硬约束框架执行搜索，用于剥离 ML 模型在硬约束下的净贡献。本方案 **ML+Guard** 则是在 ML 风险硬约束基础上叠加手工几何保底机制。

实验结果如表 1 所示。

表 1: 路径规划消融实验对比，共 81 个测试任务


方法	代价/约束类型	成功率	平均绕路比	最大风险均值
原始 2.5D A*	仅三维欧氏距离	0.0%	1.00	0.885
手工代价 A*	距离 + 几何粗糙度软惩罚	22.2%	1.03	0.542
ML 风险 A*	距离 + ML 预测风险软惩罚	38.5%	1.08	0.410
纯几何规则硬约束 A*	手工几何规则硬约束	40.7%	1.25	0.408
本方案 ML+Guard	ML 复合硬约束	55.6%	1.32	0.358

从表 1 可以得出：


1. 采用软惩罚的方法由于代价尺度不统一，依然存在为缩短距离而强行穿越危险区域的现象，导致成功率偏低。
2. 相较于仅依赖手工几何规则作为硬约束的方法，成功率 40.7%，引入经 PSO 优化的多任务 ML 模型后，本方案成功率提升至 55.6%，提升近 15 个百分点。根本原因在于手工几何规则缺乏弹性，例如对所有微小凸起一律判定为高危；而 ML 模型精确学到了特定车辆真实跨障的物理边界，从而在保持低风险的同时，解锁了大量原本被粗糙规则误杀的狭窄安全通道，最终将最大风险均值降到仅 0.358。

5.3 定性分析：不同车型的路径规划分化


外层 A* 规划调用内层 ML 模型后，最直观的成果体现在同一复杂地形下，针对不同参数车辆展现出的差异化路径选择。我们选取了一处典型的散落障碍场景，对三种代表性车辆的规划路径进行对比，结果如图 3 所示。



(a) 小型城市车



(b) 标准越野车



(c) 大型山地车

图 3: 同一散落障碍地形下不同车型的规划路径对比, 红线为本方案

观察图 3 中本方案规划路径（红色实线），可以看出不同车型之间显著的路径分化。

小型城市车轮径仅 0.06 m，底盘高度 0.04 m，中央密集坑洼与凸起属于高风险区。本方案 A* 放弃中央路线，沿地图边缘平滑绕行，路径 21.4 m，平均风险仅 0.10。标准越野车和大型山地车具备较强的跨障与抗侧翻能力，从地图左侧切入沿底部穿行，两者走向一致。其中大型山地车轮径 0.15 m、离地间隙 0.13 m，拐角处更紧凑，路径 17.5 m，略短于标准越野车的 17.7 m，平均风险均为 0.19。

相比之下，传统 2.5D A* 对三种车型均给出笔直对角线（约 13.7 m），直接贯穿高差剧变区，极大概率翻车或托底。纯手工几何约束方法虽产生一定弯折，但缺乏对风险深度的弹性判断，小车任务中平均风险仍高达 0.28。

以上结果表明,引入 ML 模型后系统具备了对不同车型通过能力的判别能力,通过 ML+Guard 避免了手工规则僵化，实现了数据驱动下因车制宜的自适应规划。

6 团队分工与总结

6.1 工作总结

本综合设计围绕机器学习与智能搜索双向协同的核心要求，形成了从问题建模、物理仿真、模型训练到规划验证的完整闭环：

1. **双向嵌套协同架构：**自主实现了内层 PSO 复合适应度寻优与外层 ML 风险约束 A*，通过代理规划评估构成反馈闭环。

- 2. **基于物理仿真的高保真数据**：借助 Gazebo 生成了 20,000 次含侧翻、托底、打滑等真实动力学标签的交互数据。
- 3. **ML+Guard 鲁棒融合机制**：将数据驱动的精细判别与几何先验保底下界融合，提升极端地形下的规划鲁棒性。
- 4. **方法创新**：将 ML 风险预测作为硬约束而非软惩罚，避免距离稀释风险；将不可微的规划成功率反馈至 PSO，实现搜索与学习的闭环。

6.2 团队分工

本团队共 3 人，分工明确，全流程无缺失，具体分工如表 2 所示。

表 2: 团队分工与完成情况

成员	核心职责与实际完成情况
崔瑞航	核心算法开发与系统架构设计 ：搭建内层 CNN+MLP 多任务风险评估模型的网络架构；设计并实现内层 PSO 搜索算法及复合适应度函数，含代理规划评估模块；实现外层带 ML+Geometric Guard 约束的 A* 算法核心逻辑；串联内外层数据流与控制流，完成耦合交互的联合调试。
李佳阳	物理仿真数据链与建模定义 ：完成问题场景的数学形式化定义与状态/动作空间建模；基于 Gazebo/ros_gz 搭建多模态地形生成流程；定义车辆实体物理参数，负责运行并提取 20,000 次局部动作的碰撞、打滑等标签；负责数据集的封装、验证与数据加载预处理。
刘动	消融实验、可视化与报告撰写 ：搭建手工代价、纯 ML 风险等多种基线方法，执行大规模消融对比实验；利用 Matplotlib/PyVista 绘制二维与三维路径对比图；汇总实验数据，进行结果统计与核心结论提炼；完成综合设计报告的 L ^A T _E X 排版与答辩材料制作。

通过本次综合大作业，团队成员深入理解了搜索算法与机器学习模型的优势互补关系，锻炼了从工程抽象、物理仿真到算法联合寻优与系统验证的端到端设计能力。

附录

代码仓库

本项目完整源代码及复现说明已开源:https://github.com/BruceCui7193/2p5d_Path_Planning_with_ML

参考文献

- [1] J. Gu and Q. Cao. Path planning for mobile robot in a 2.5-dimensional grid-based map. *Industrial Robot*, 38(2):126–134, 2011. DOI: 10.1108/01439911111122815.